

Sesión 9: Inferencia Estadística

1

EUSEBIO ANGULO SÁNCHEZ-HERRERA

CURSO 2022/2023



**ESCUELA SUPERIOR
DE INFORMÁTICA
CIUDAD REAL**





Contenidos Principales



2

- Intervalos de confianza (CI) y Contraste de Hipótesis (HT)
 - ✦ dos muestras
 - ✦ Reglas de significación
 - ✦ p-valor
 - Rechazamos H_0 cuando $p\text{-valor} \leq \alpha$
- Datos independientes
 - ✦ Test de igualdad de varianzas -> Test de medias
- Datos pareados
 - ✦ Test de medias para datos pareados

independientes: primero hacer test de igualdad
pareadas:



Distribución Normal



3

n grande -> teorema central del limite para asumir normalidad

- Métodos paramétricos
 - ✦ Solo utilizables cuando los datos siguen una distribución normal.
 - ✦ De lo contrario, sería necesario utilizar métodos no paramétricos.

- El Teorema Central del Límite
 - ✦ Si “ n es lo suficientemente grande”, podemos asumir la normalidad, entonces tenemos un modelo que responde a los parámetros...



Ejemplo Grosor de Aislamiento



4



insulation1<-c(10.3,10.1,9.8,9.9,10.2,10.1,9.7,9.9,9.7,10.2)

insulation2<-c(9.9,10.1,9.5,9.3,10.2,10,9.1,9.5,9.8,10.1)




Ejemplo Grosor de Aislamiento



5

○ `boxplot(insulation1,insulation2)`



✦ `summary(insulation1)`

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
9.700	9.825	10.000	9.990	10.170	10.300

✦ `summary(insulation2)`

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
9.10	9.50	9.85	9.75	10.07	10.20



Ejemplo Grosor de Aislamiento



6

- ¿Hay diferencias significativas entre las medias de las muestras?

- Estadísticamente

$$\begin{cases} H_0 : \mu_1 = \mu_2 \\ H_1 : \mu_1 \neq \mu_2 \end{cases}$$

- Estamos asumiendo normalidad pero $n=10$ es pequeño y nosotros necesitaríamos métodos no paramétricos.



Distintos planteamientos



7

- Datos independientes:

- ✧ Varianzas iguales

`var.equal = true`

- Varianzas desconocidas e iguales: $T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{(n_1 - 1)S_{c1}^2 + (n_2 - 1)S_{c2}^2}{n_1 + n_2 - 2} \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$.

- ✧ Varianzas distintas

`var.equal = false`

- Varianzas desconocidas y distintas: $T = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_{c1}^2}{n_1} + \frac{S_{c2}^2}{n_2}}}$

- Datos pareados:

`paired = true`

- Dos medias (muestras relacionadas): $T = \frac{\bar{X}_1 - \bar{X}_2}{\frac{S_{cD}}{\sqrt{n}}}$.



Distintos planteamientos



8

Datos independientes o pareados



1º) Test varianzas desconocidas e iguales
> **var.test**

2º) Test de media
> **t.test with var equal (or unequal)**



1º) Test de medias (muestras relacionadas)

> **t.test with paired data**



¿Independiente o Pareado?



9



- 1) El grosor del aislamiento medido en dos edificios diferentes en paredes distintas.
- 2) El grosor del aislamiento medido en varias paredes de un edificio en verano e invierno.



¿Independiente o Pareado?



10



- 1) El grosor del aislamiento medido en dos edificios diferentes en paredes distintas. **INDEPENDIENTE**
- 2) El grosor del aislamiento medido en varias paredes de un edificio en verano e invierno. **PAREADO**



2 medias independientes



11


Primero, nosotros necesitamos un test de varianzas:

test de varianzas

$$\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_1 : \sigma_1^2 \neq \sigma_2^2 \end{cases}$$

\sim

$$\begin{cases} H_0 : \frac{\sigma_1^2}{\sigma_2^2} = 1 \\ H_1 : \frac{\sigma_1^2}{\sigma_2^2} \neq 1 \end{cases}$$





var.test()



12

```
var.test(insulation1,insulation2)
```

F test to compare two variances

data: insulation1 and insulation2

$F = 0.33385$, num df = 9, denom df = 9, **p-value = 0.1178**

se acepta H_0 $0,1178 < 0,05$ las varianzas son iguales

alternative hypothesis: true ratio of variances is not equal to 1

95 percent confidence interval:

0.08292415 1.34408677

sample estimates:

ratio of variances

0.3338521

Decision Rule...

'We reject H_0 when $p\text{-value} \leq \alpha$ '



desired significance level (beforehand)

In general $\alpha = 0.05$



2 medias independientes: test de medias




13

Contraste de Hipótesis bilateral:

$$\begin{cases} H_0 : \mu_1 = \mu_2 \\ H_1 : \mu_1 \neq \mu_2 \end{cases}$$

\sim

$$\begin{cases} H_0 : \mu_1 - \mu_2 = 0 \\ H_1 : \mu_1 - \mu_2 \neq 0 \end{cases}$$





2 medias independientes



14

$\sigma_1 = \sigma_2$ (como hemos comprobado anteriormente)

```
t.test(insulation1,insulation2,var.equal = TRUE)
```

Two Sample t-test

data: insulation1 and insulation2

$t = 1.7391$, $df = 18$, $p\text{-value} = 0.09909$ se rechaza H_0

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-0.04993062 0.52993062

sample estimates:

mean of x mean of y

9.99 9.75

Decision Rule...

'We reject H_0 when

- statistic \in Critical Region (α)
- $p\text{-value} \leq \alpha$
- reference value for "parameter" $\notin (1 - \alpha)\%$ CI



Tipos de hipótesis en R



15

$H_1 : \dots \neq \dots \xRightarrow{R} \text{'two.sided' (by default)}$
 $H_1 : \dots < \dots \xRightarrow{R} \text{'less'}$
 $H_1 : \dots > \dots \xRightarrow{R} \text{'greater'}$

$H_1 : \mu_x < \mu_y$
 $H_1 : \mu_y > \mu_x$

is the same! \Rightarrow **Data order** \Downarrow

`t.test(x,y,...alt="less"...)`


`t.test(y,x,...alt="greater"...)`



Ejemplos tests unilaterales



16



todas las combinaciones que se pueden demostrar

- > t.test(insulation1, insulation2, alternative = “less”)
- > t.test(insulation1, insulation2, alternative = “greater”)
- > t.test(insulation2, insulation1, alternative = “less”)
- > t.test(insulation2, insulation1, alternative = “greater”)



Media con datos pareados



17

Grosor del aislamiento medido en varias paredes de un edificio en verano e invierno



Test de Hipótesis Bilateral:

$$\begin{cases} H_0 : \mu_1 = \mu_2 \\ H_1 : \mu_1 \neq \mu_2 \end{cases}$$

\sim

$$sample1_i - sample2_i = D_i$$

$$\begin{cases} H_0 : \mu_D = 0 \\ H_1 : \mu_D \neq 0 \end{cases}$$



Media con datos pareados



18

```
> t.test(insulation1, insulation2, paired = TRUE)
```

pareados

Paired t-test

data: insulation1 and insulation2

$t = 2.9794$, $df = 9$, **p-value = 0.01547** se rechaza H_0 , medias distintas

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

0.05777501 0.42222499

sample estimates:

mean of the difference

0.24

Decision Rule...

'We reject H_0 when

- statistic \in Critical Region (α)
- p-value $\leq \alpha$
- reference value for "parameter" $\notin (1 - \alpha)\% \text{ CI}$



Ejercicio 1



19

- Se han probado dos marcas de automóviles comparando las velocidades máximas que alcanzan. Se han hecho 12 pruebas con cada uno de los vehículos obteniendo los siguientes resultados:
A: 256, 239, 222, 207, 228, 241, 212, 216, 236, 219, 225, 230
B: 212, 240, 263, 275, 237, 271, 261, 223, 234, 220, 232, 230
- Suponiendo normalidad en la variable ¿existe evidencia estadística de que el vehículo de la marca B alcanza velocidades máximas en promedio mayores que el de la marca A?
(Considerar una significancia del 5%)



Ejercicio 1 b



20

- Se han probado dos marcas de automóviles comparando las velocidades máximas que alcanzan. Se han hecho 12 pruebas con cada uno de los vehículos obteniendo los siguientes resultados:
A: 256, 239, 222, 207, 228, 241, 212, 216, 236, 219, 225, 230
B: 247, 219, 270, 282, 244, 278, 268, 230, 227, 241, 239, 237
- Suponiendo que los datos siguen una distribución normal, ¿existe evidencia estadística de que el vehículo de la marca B es **5km/h** mayor que la velocidad máxima media de la marca A con una significancia del 5%?



Ejercicio 2



21

- El departamento de calidad de una empresa quiere comprobar si se mantiene el nivel de calidad de un producto de una semana a otra, tras un incidente registrado durante el fin de semana. La calidad del artículo se supone normalmente distribuida y se han obtenido los siguientes resultados de una m.a.s de 8 productos:
Semana1: 93, 86, 90, 90, 94, 91, 92, 96
Semana2: 93, 87, 97, 90, 88, 87, 84, 93
- Realizar el contraste correspondiente a un nivel de significación del 1% que permita discriminar si se mantiene el nivel de calidad.



Ejercicio 3



22

Ejercicio 5.2.8 Examen Extraordinario 2018

- El número diario de twits realizados durante los 5 días previos al examen que contienen el hashtag #laestadisticamola han sido: 50, 42, 53, 60, 37. Mientras tanto, el número de twits que contenían el hashtag #aprobareestadistica esos mismos días ha sido de: 40, 51, 62, 55 y 64. Si suponemos que ambas distribuciones de tuits se pueden considerar normales y considerando un nivel de significación del 5%, se pide:
- ¿Podemos concluir que el número de twits medio que contienen el hastagh #laestadisticamola es mayor que 39?
- Comprobar si podemos llegar a la conclusión de que las medias del número de tuits que usan esos hashtags difieren.